

PROCESAMIENTO DE SEÑALES EMG




- Alvaro Untiveros
- Fiorella Pérez
- Lucero Munive



LAB 8 ISB


1: ADQUISICIÓN Y ACONDICIONAMIENTO

- **Adquisición de la Señal:** Las señales mioeléctricas, que representan la actividad eléctrica de los músculos, se capturan generalmente de forma no invasiva mediante electrodos de superficie. Estos electrodos, comúnmente de Plata-Cloruro de Plata (Ag/AgCl), se colocan sobre la piel en la zona del músculo de interés.
- **Amplificación:** Las señales EMG crudas tienen una amplitud muy baja (en el orden de microvoltios a milivoltios), por lo que es indispensable una etapa de amplificación para aumentar su magnitud y facilitar su posterior procesamiento.
- **Filtrado Inicial:** Una vez amplificada, la señal es susceptible a diversos tipos de ruido. El proceso de filtrado es esencial para eliminar interferencias:
 - **Reducción de Ruido:** Se utilizan amplificadores diferenciales que ayudan a anular el ruido común, como la interferencia de la línea eléctrica (50/60 Hz).
 - **Filtro Pasa-Banda:** Se aplica un filtro que combina un filtro pasa-altas y uno pasa-bajas para seleccionar el rango de frecuencia relevante de la señal EMG, que típicamente se encuentra entre 0 y 500 Hz. Esto permite eliminar artefactos de movimiento (bajas frecuencias) y ruido de alta frecuencia. Frecuentemente se emplean filtros como el de Butterworth por su respuesta plana.



CNN : RED NEURONAL CONVOLUCIONAL

Diseñada para detectar patrones espaciales o temporales en datos estructurados.



Arquitectura de CNN [1]



<https://datascientest.com/es/convolutional-neural-network-es#:~:text=Las%20CNN%20designan%20una%20subcategor%C3%ADa,im%C3%A1genes%20considerados%20como%20m%C3%A1s%20eficaces.&text=A%20primera%20vista%20su%20modo,forma%20de%20matriz%20de%20p%C3%ADxeles.>

CNN : RED NEURONAL CONVOLUCIONAL


Reconocimiento de gestos con la mano mediante CNN compacta a través de señales de electromiografía de superficie [2]

Objetivo principal: diseñar una arquitectura CNN más compacta y eficiente para clasificar gestos de la mano a partir de señales de electromiografía de superficie (sEMG), reduciendo la complejidad del modelo y mejorando la precisión frente a otros métodos como LSTM .

Brazalete Myo de 8 canales



EMGNet



4 capas convolucionales

LSTM: MEMORIA A CORTO Y LARGO PLAZO

Las redes LSTM son un tipo de red neuronal recurrente (RNN) especialmente diseñadas para aprender dependencias a largo plazo en datos secuenciales, lo que las hace idóneas para el análisis directo de las señales EMG en el dominio del tiempo. Mitigando problemas como el gradiente que se desvanece en RNNs tradicionales.


01 Señal Pre-procesada Directa

La señal EMG, después de ser filtrada y normalizada, se segmenta en ventanas. Estas secuencias de datos crudos se pueden introducir directamente en la red LSTM. La red aprende a extraer las características temporales relevantes por sí misma.

02 Feature Engineering

Para reducir la dimensionalidad y, en algunos casos, mejorar el rendimiento, se pueden calcular características temporales sobre ventanas de la señal. Algunas características comunes son:

- **Valor Medio Absoluto (MAV):** Una medida de la amplitud de la señal.
- **Varianza (VAR):** Indica la potencia de la señal.
- **Cruce por Cero (ZC):** El número de veces que la señal cruza el eje cero, relacionado con el contenido frecuencial.




Para:

- **Clasificación de movimientos**
- **Predicción y Regresión de la cinemática continua del movimiento**

<https://pmc.ncbi.nlm.nih.gov/articles/PMC8512101/#B32-sensors-21-06369%5D>

A Muscle Fatigue Classification Model Based on LSTM and Improved Wavelet Packet Threshold [3]

Árbol de descomposición de paquetes wavelet en el nivel 3



Funciones de umbrales clásicas

The hard threshold function is calculated as follows:

$$\hat{w}_{j,k} = \begin{cases} w_{j,k}, & |w_{j,k}| \geq \lambda \\ 0, & |w_{j,k}| < \lambda \end{cases}$$

The soft threshold function is expressed as follows:

$$\hat{w}_{j,k} = \begin{cases} \text{sign}(w_{j,k})(|w_{j,k}| - \lambda), & |w_{j,k}| \geq \lambda \\ 0, & |w_{j,k}| < \lambda \end{cases}$$

Función de umbral (threshold) mejorada

$$\hat{w}_{j,k} = \begin{cases} w_{j,k} - \frac{m \cdot w_{j,k}}{1 + \log(\frac{|w_{j,k}|}{\lambda})}, & |w_{j,k}| \geq \lambda \\ \frac{(1-m)\text{sign}(w_{j,k})|w_{j,k}|^{k+1}}{(1 - \log(\frac{|w_{j,k}|}{\lambda})\lambda^k)}, & |w_{j,k}| < \lambda \end{cases}$$


When $|w_{j,k}| \rightarrow \lambda^+$, Equation (4) can be written as:

$$\lim_{|w_{j,k}| \rightarrow \lambda^+} (w_{j,k} - \frac{m \cdot w_{j,k}}{1 + \log(\frac{|w_{j,k}|}{\lambda})}) = (1 - m)\lambda.$$

When $|w_{j,k}| \rightarrow \lambda^-$, Equation (4) can be written as:

$$\lim_{|w_{j,k}| \rightarrow \lambda^-} (\frac{(1 - m)\text{sign}(w_{j,k})|w_{j,k}|^{k+1}}{(1 - \log(\frac{|w_{j,k}|}{\lambda})\lambda^k)}) = (1 - m)\lambda.$$

Matriz de confusión para los datos de características sEMG



ESPECTROGRAMAS PARA EL ANÁLISIS FRECUENCIAL [4]

Los espectrogramas permiten visualizar cómo cambia el contenido de frecuencia de la señal EMG a lo largo del tiempo, convirtiendo una señal unidimensional en una imagen 2D que puede ser procesada por modelos de visión por computadora.

01 Transformada de Fourier de Tiempo Corto (STFT)

Tras el acondicionamiento inicial, la señal EMG se segmenta en pequeñas ventanas de tiempo superpuestas. A cada una de estas ventanas se le aplica la Transformada de Fourier para obtener el espectro de frecuencia en ese instante. La STFT es fundamental para analizar señales cuya frecuencia varía con el tiempo.

Transformada Q Constante (CQT)


$$Q = \frac{f_k}{\Delta f_k}$$

02 Generación del Espectrograma:

Al combinar los espectros de frecuencia de todas las ventanas, se genera un espectrograma. Este es una representación visual en 2D donde un eje representa el tiempo, el otro la frecuencia, y la intensidad del color indica la potencia o magnitud de la señal en esa frecuencia y tiempo específicos.

Para:

- Extraer características aplicables a modelos de DL
- Clasificación de gestos o movimientos
- Aprender patrones específicos



User identification system based on 2D CQT spectrogram of EMG with adaptive frequency resolution adjustment

Scientific Reports - User identification system based on 2D CQT spectrogram of EMG with adaptive frequency resolution adjustment

Nature / Jan 16, 2024

MODELOS HÍBRIDOS - CNN-LSTM

Las señales EMG tienen dos dimensiones de información importantes: Espacial (o multicanal) → cada electrodo capta un músculo distinto.
Temporal (dinámica) → la contracción y relajación cambian con el tiempo.

CNN + **LSTM**


Analiza patrones locales o espaciales. Actúa como extractor de características (feature extractor).

Analiza dependencias temporales. Actúa como modelador secuencial, interpretando esas características a lo largo del tiempo.

=


Juntas, permiten reconocer movimientos más naturales y complejos, con mayor precisión y estabilidad incluso con señales EMG ruidosas o variables entre sujetos.

Artículo 1 [5]




Application Research on Optimization Algorithm of sEMG Gesture Recognition Based on Light CNN+LSTM Mode [5]

Artículo 2 [6]



EMGHandNet: A hybrid CNN and Bi-LSTM architecture for hand activity classification using surface EMG signals [6]



AUTOENCODERS PARA LA EXTRACCIÓN NO SUPERVISADA DE CARACTERÍSTICAS

Un Autoencoder (AE) es una red neuronal no supervisada que aprende a reconstruir su propia entrada. Está formado por dos partes: el Encoder o codificador y el Decoder o decodificador. El objetivo de un AE es aprender una representación interna útil de los datos.

01 ENCODER

Comprime la señal EMG en un vector pequeño (llamado latent vector o representación latente).

02 DECODER

Intenta reconstruir la señal original a partir del vector latente

03 DENOISING

Durante el entrenamiento, se introduce ruido artificial en la señal EMG de entrada. La red no se entrena para reconstruir esta entrada ruidosa, sino la señal original y limpia. Esto obliga al modelo a aprender la estructura fundamental de la señal EMG y a ignorar el ruido, resultando en características mucho más robustas.


04 STACKED

Se entrenan múltiples capas de autoencoders de forma secuencial. La salida (las características aprendidas) de una capa se convierte en la entrada de la siguiente, permitiendo al modelo aprender características cada vez más complejas y abstractas.

05 VAE


En lugar de aprender un único vector latente, aprende una distribución (media y varianza) que describe todas las posibles representaciones del dato.

On autoencoders for extracting muscle synergies: A study in highly variable upper limb movements [7]





<https://www.sciencedirect.com/science/article/pii/S1746809425004513>

REFERENCIAS:



- [1] Convolutional Neural Network [Internet]. Formación en ciencia de datos | DataScientest.com. 2021. Available from: <https://datascientest.com/es/convolutional-neural-network-es>
- [2] Chen L, Fu J, Wu Y, Li H, Zheng B. Hand Gesture Recognition Using Compact CNN via Surface Electromyography Signals. Sensors. 2020 Jan 26;20(3):672. Available from: <https://www.mdpi.com/1424-8220/20/3/672>
- [3] Wang J, Sun S, Sun Y. A Muscle Fatigue Classification Model Based on LSTM and Improved Wavelet Packet Threshold. Sensors (Basel, Switzerland) [Internet]. 2021 Sep 24 [cited 2022 Aug 19];21(19):6369. Available from: <https://pubmed.ncbi.nlm.nih.gov/34640689/>
- [4] Kim JM, Choi G, Pan S. User identification system based on 2D CQT spectrogram of EMG with adaptive frequency resolution adjustment. Scientific Reports. 2024 Jan 16;14(1). Available from: <https://www.nature.com/articles/s41598-024-51791-4>
- [5] Bai D, Liu T, Han X, Yi H. Application Research on Optimization Algorithm of sEMG Gesture Recognition Based on Light CNN+LSTM Model. Cyborg and Bionic Systems. 2021 Nov 8;2021:1–12. Available from: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9494710/>
- [6] Karnam NK, Dubey SR, Turlapaty AC, Gokaraju B. EMGHandNet: A hybrid CNN and Bi-LSTM architecture for hand activity classification using surface EMG signals. Biocybernetics and Biomedical Engineering. 2022 Jan;42(1):325–40. Available from: <https://www.sciencedirect.com/science/article/abs/pii/S0208521622000080>
- [7] Giraud M, Brambilla C, Guanziroli E, Facciorusso S, Molinari Tosatti L, Molteni F, et al. On autoencoders for extracting muscle synergies: A study in highly variable upper limb movements. Biomedical Signal Processing and Control [Internet]. 2025 Apr 21;108:107940. Available from: <https://www.sciencedirect.com/science/article/pii/S1746809425004513>



GRACIAS